

Data & AI practicum

Klinische chemie themawEEK BMT



William van Doorn, PhD
Klinisch chemicus

Wat gaan we deze ochtend doen?

- Korte introductie van probleem en opdracht (30min)
- Zelfstandig bouwen aan oplossing (groepsverband)
 - Technisch ontwikkeling van (AI) model
 - Nadenken over wat belangrijk is bij implementatie
- Pitches & uitslag van wedstrijd! (45m)



De klassieke klinische chemie




- (bijna) veel verschillende apparaten
 - Veel bloedvolume
 - Expertise
 - (vaak) enkel op centraal lab
- Beperkt tot denkvermogen dokter/lab

De klinische chemie 2.0

- Kunnen we niet met één meting meer informatie uit het bloed verzamelen? Kijken naar patronen?
 - Voorwaarde: één simpele, laag-volume meting die informatie over meerdere analyten kan verschaffen?
- “moleculaire fingerprint” van het bloed?




Basisprincipe infrarood spectroscopie



Huidige gebruik infrarood spectra


Infrared spectrum



Referentie tabel



Band	Wavenumber/cm ⁻¹	Functional group/ molecular motion	Chemical class
A	3390–3232	OH Stretching	Alcohols
B	2914	CH ₂ Asymmetric stretching	Alkanes
C	2849	CH ₂ Symmetric stretching	Alkanes
D	1733	C=O Stretching	Esters
E	1701	C=O Stretching	Esters
F	1542–1560	–COO ⁻ Asymmetric stretching	Carboxylates
G	1461	CH ₂ Bending	Alkanes
H	1411	–COO ⁻ Symmetric stretching	Carboxylates
I	1170	C–O Stretching	Esters
J	956	C–H Bending	Alkanes
K	780	C–H Torsion band	Alkanes
L	719	CH ₂ Rocking	Long chain alkanes

De klinische chemie 2.0



Kreatinine 200 $\mu\text{mol/L}$
ALAT 50 U/L
Hemoglobine 8 mmol/L

Nierziekte ja/nee?
Prognose ... jaar ?




300x



ALAT	Calcium	Gamma-GT	Potassium
Albumin	Chlorine	Iron	Sodium
Alk. Phosph.	Cholesterol	LD	Bilirubin
Amylase	CK	Lipase	Total protein
ASAT	Creatinine	Magnesium	Triglycerides
Bilirubin dir.	CRP	Phosphate	Urea

Causes of death in the world



Cardiovasculaire ziekten in de huisartsenpraktijk

- “Cardiovasculair risicomanagement”: één van de **kerntaken** van de huisarts gezien hoge prevalentie en ernstige mortaliteit
- Cardiovasculair risicoprofiel

Leeftijd:	
Geslacht:	M ☒ V ☐
Hart-vaatziekten: ⓘ	Ja ☐ Nee ☒
Diabetes mellitus:	Ja ☐ Nee ☒
Roken:	Ja ☐ Nee ☒
Bloeddruk systol.: (mmHg)	
Cholesterol tot.: (mmol/l)	b.v. 5.3
Chronische nierschade: ⓘ	Geen v
Reuma: ⓘ	Ja ☐ Nee ☒
Hdl-cholesterol: (mmol/l)	b.v. 0.9
Berekenen Risico →	

Leeftijd:

Geslacht: M ☒ V ☐

Hart-vaatziekten: ☒ Ja ☐ Nee ☐

Diabetes mellitus: ☐ Ja ☒ Nee ☐

Roken: ☒ Ja ☐ Nee ☐

Bloeddruk systol.: (mmHg)

Cholesterol tot.: (mmol/l) b.v. 5.3


Chronische nierschade:

Reuma: ☒ Ja ☐ Nee ☐

Hdl-cholesterol: (mmol/l) b.v. 0.9

Berekenen Risico

Risicoschatting is van toepassing voor patiënten van 45-65 jaar en kan **niet** gebruikt worden als de patient preventieve medicatie tegen hart-vaatziekten gebruikt.



Tienjaarssterfterisico:

10%

Zeer hoog risico

Indicatie van het tienjaarsrisico op ziekte en sterfte:

Bovengrens: 51%

Ondergrens: 40%

Advies

Zeer hoog risico

Streefwaarde LDL-cholesterol (mmol/l)			Streefwaarde systolische bloeddruk (mmHg)			Beleid
≤ 70 jaar	> 70 jaar		≤ 70 jaar	> 70 jaar		
	Niet kwetsbaar	kwetsbaar		Niet kwetsbaar	kwetsbaar	
< 1.8	< 2.6	Indien medicatie wordt gegeven bij voldoende levensverwachting: <2.6	< 140 (eventueel < 130)	< 150 (eventueel < 140)	< 150 en ≥ 70 diastolisch	Leefstijl advies Medicamenteuze therapie meestal aangewezen

✓ Leeftijd:

✓ Geslacht: M ☒ V ☐

✓ Hart-vaatziekten: Ja ☐ Nee ☒

✓ Diabetes mellitus: Ja ☐ Nee ☒

✓ Roken: Ja ☐ Nee ☒

✓ Bloeddruk systol.: (mmHg)


Cholesterol tot.: b.v. 5.3 (mmol/l)

✓ Chronische nierschade: Geen


✓ Reuma: Ja ☐ Nee ☒

Hdl-cholesterol: b.v. 0.9 (mmol/l)


Berekenen Risico →



huidig




de oplossing



Opdracht van vandaag

(1) Technisch: ontwikkelen van model wat cholesterol kan voorspellen op basis van infrarood spectrum

- ✓ ontwikkelen model; geblindeerde evaluatie van model → wedstrijd 😊
- ✓ pitch over technische ontwikkeling (4min)



Opdracht van vandaag

(1) Technisch: Ontwikkelen van model wat cholesterol kan voorspellen op basis van infrarood spectrum

✓ ontwikkelen model; geblindeerde evaluatie van model → wedstrijd 😊

✓ pitch over technische ontwikkeling (4min): ontwikkeling, keuzes, prestaties

(2) Voorwaarden: Nadenken over randvoorwaarden voor succesvolle implementatie van research → zorg!

✓ pitch over randvoorwaarden op bepaald thema (4min): nadenken over vragen

Technisch

- Bestudeer use-case: wat moet het model voorspellen?
- Bestudeer en verwerk data
- Bestudeer algoritmen en kies oplossing
- Ontwikkel model
 - Data processing
 - Ontwikkel / validatie dataset
 - Under vs overfitting
 - Evalueer resultaat
- Toets model op 'blinde' data

Waarde

Welke stakeholders wil je betrekken bij ontwikkeling en implementatie?
Wat is de maatschappelijke / economische meerwaarde?
Is er een economische meerwaarde van dit product? Probeer een eerste beknopte business case te maken.

Ethiek

Hoe zorg je dat het model eerlijk presteert voor verschillende patiëntgroepen?
Welke risico's ontstaan als zorgverleners te veel vertrouwen op dit algoritme?
Hoe zouden jullie uitlegbaarheid richting gebruiker vormgeven?

Verantwoording

Aan welke regelgeving of certificering zou dit idee moeten voldoen (bijv. IVDR, CE)?
Wie zou juridisch verantwoordelijk zijn als dit model een verkeerde voorspelling doet?
Mag je zomaar patiëntendata gebruiken?

Toepassing

Wie zijn je eindgebruikers van dit product?
Wat is er nodig (in workflow, scholing of technologie) om dit in praktijk te brengen?
In welke zorgcontext zou jullie oplossing het best passen (huisarts, ziekenhuis, zelftest)?

Handvaten voor practicum


Scope en doel

- Doel: ontwikkel een model dat cholesterol voorspelt o.b.v. infrarood spectra
→ Algoritme “leren” cholesterol te voorspellen o.b.v. karakteristieken in infrarood-spectrum
- Formuleer concreet je methodiek
 - Wat is je label / target-variabele?
 - Wat zijn de input variabelen van je model?
- Bedenk eerste oplossing / techniek voor je probleem
 - Regressie vs classificatie?
 - Welk model/techniek zou geschikt zijn?
 - Hoe evalueer je het model? (e.g. correlatie, error, ..?)

Handvaten voor practicum

Data


- Inspecteer & exploreer de data
- Stel jezelf de vragen
 - Zijn er missende data / outliers?
 - Hoe is verdeling van mijn input en output data?
 - Moet ik aan data processing doen?
- Zorg dat je de data splitst in ontwikkel (70%) en test (30%) sets
 - Waarom is dit belangrijk?



Handvaten voor practicum

Dataset

- .CSV en Excel
- 290 samples met label (cholesterol concentratie) en 90 variabelen → elke kolom is de gemeten absorptie per 40nm golflengte




	A	B	C	D	E	F	G	H	I	J
1	cholesterol_mmol_L	wl_432	wl_472	wl_512	wl_552	wl_592	wl_632	wl_672	wl_712	wl_752
2	5,13	-0,0130	-0,0017	0,0177	-0,0050	0,0270	0,0529	0,0791	0,1842	0,2237
3	5,12	-0,0300	-0,0191	0,0086	0,0035	0,0432	0,1379	0,2701	0,5262	0,7181
4	3,87	-0,0188	0,0229	-0,0173	-0,0353	-0,0625	-0,2046	-0,5282	-1,0152	-1,4565
5	5,15	-0,0367	0,0240	-0,0022	0,0018	0,0404	0,1644	0,3048	0,6221	0,9118
6	4,47	0,0333	-0,0263	0,0328	-0,0147	0,0266	-0,0614	-0,1310	-0,2106	-0,2817
7	4,67	0,0135	-0,0048	-0,0341	-0,0182	0,0161	0,0407	0,1221	0,2595	0,2959
8	5,63	-0,0198	0,0082	-0,0034	-0,0387	-0,0327	-0,1094	-0,2029	-0,3903	-0,6456
9	4,25	-0,0291	-0,0092	-0,0363	0,0148	-0,0464	-0,0553	-0,2043	-0,3472	-0,4872
10	4,05	-0,0092	0,0210	0,0055	-0,0026	0,0247	0,1022	0,2587	0,4551	0,5966
11	4,96	0,0159	0,0029	-0,0152	0,0250	-0,0162	0,0209	0,1171	0,2645	0,4184
12	4,19	0,0150	-0,0056	-0,0040	0,0152	0,0467	0,1022	0,2811	0,4567	0,5102
13	3,57	0,0131	-0,0196	-0,0031	-0,0377	-0,0339	-0,0851	-0,2781	-0,5275	-0,6236

Handvaten voor practicum

Ontwikkeling van model

- Bestudeer verschillende type modellen
 - Lineaire regressie?
 - Decision Tree / Random Forest?
 - Neuraal Netwerk?
 - ..
- Kies model en ontwikkel model op trainingsdata
- Onderbouw keuze model
- Kies praktische invulling: ga je programmeren? (Python, Matlab), ga je een “no code” oplossing gebruiken? Welke expertise heeft ons groepje?



Handvaten voor practicum

Evalueer & itereer

- Evalueer op testset (waarom?)
 - Hoe goed werkt het?
 - Welke evaluatie maat is belangrijk?
- Visualiseer resultaten
- Itereer: kunnen we nog stappen ondernemen om het te verbeteren?
- Omstreeks 11.45: finale evaluatie op 10 geblindeerde infrarood spectra

Handvaten voor practicum

Handige URL's

- Ben inventief (ChatGPT?)
- 'Ouderwetse' bronnen
 - Regression trees in MATLAB:
<https://nl.mathworks.com/help/stats/train-regression-trees-using-regression-learner-app.html>
 - Regression tree in Python:
<https://data36.com/regression-tree-python-scikit-learn/>
 - Linear Regression in Python:
https://www.w3schools.com/python/python_ml_multiple_regression.asp

Technisch

- Bestudeer use-case: wat moet het model voorspellen?
- Bestudeer en verwerk data
- Bestudeer algoritmen en kies oplossing
- Ontwikkel model
 - Data processing
 - Ontwikkel / validatie dataset
 - Under vs overfitting
 - Evalueer resultaat
- Toets model op 'blinde' data

Waarde

1

Welke stakeholders wil je betrekken bij ontwikkeling en implementatie?
Wat is de maatschappelijke / economische meerwaarde?
Is er een economische meerwaarde van dit product? Probeer een eerste beknopte business case te maken.

Ethiek

2

Hoe zorgen jullie dat het model eerlijk presteert voor verschillende patiëntgroepen?
Welke risico's ontstaan als zorgverleners te veel vertrouwen op dit algoritme?
Hoe zouden jullie uitlegbaarheid richting gebruiker vormgeven?

Verantwoording

3

Aan welke regelgeving of certificering zou dit idee moeten voldoen (bijv. IVDR, CE)?
Wie zou juridisch verantwoordelijk zijn als dit model een verkeerde voorspelling doet?
Mag je zomaar patiëntendata gebruiken?

Toepassing

4

Wie zijn je eindgebruikers van dit product?
Wat is er nodig (in workflow, scholing of technologie) om dit in praktijk te brengen?
In welke zorgcontext zou jullie oplossing het best passen (huisarts, ziekenhuis, zelftest)?

Handvaten voor practicum



Dataset (.CSV)

https://wptmdoorn.github.io/onderwijs/aipracticumbmt/FTIR%20data_train_students.csv




Dataset (Excel)

https://wptmdoorn.github.io/onderwijs/aipracticumbmt/FTIR%20data_train_students.xlsx



Hand-outs

<https://wptmdoorn.github.io/onderwijs/aipracticumbmt/260319handouts.pdf>




MATLAB template

https://wptmdoorn.github.io/onderwijs/aipracticumbmt/ai_practicum_bmt.m



Python template

https://wptmdoorn.github.io/onderwijs/aipracticumbmt/ai_practicum_bmt.py



No-code browser tool

<https://csvtoolsonline.com/tools/no-code-ml-model-builder>